CENSO 2020 · CHIAPAS

Auditoría Territorial Inteligente de la Vulnerabilidad Hídrica en Chiapas

Pipeline predictivo no lineal con XGBoost y SHAP para la ONG Cántaro Azul

Santiago Díaz · Data Science II: Machine Learning para la Ciencia de Datos - CoderHouse · Octubre de 2026

El reto del acceso al agua en Chiapas

21,157

localidades en el Censo 2020: un diagnóstico manual en campo es inviable

44%

de las localidades (9,385) sin dato de agua por secreto estadístico, pero solo ≈0.9% de la población

11,772

localidades modelables con cobertura de agua observada

Objetivo: una herramienta analítica que ordene las comunidades según su rezago hídrico para orientar el uso de los recursos.

Variable objetivo relativa: la mediana estatal

98.0%

mediana de cobertura de agua entubada por localidad

- Un umbral fijo inicial generó clases extremadamente desbalanceadas (99.7% en una clase) e invalidaba el modelo.
- Solución: **clase 1 = cobertura por debajo de la mediana estatal**. Resultado: clases 50% / 50%.
- Lectura honesta: la clase 1 significa «menos cobertura que la localidad típica», no necesariamente una crisis. El modelo sirve para ordenar y priorizar.

Validación agrupada por municipio

0.730

AUC en validación cruzada agrupada por municipio (GroupKFold, 5 particiones): estimación conservadora

0.751

AUC en test aleatorio 20% estratificado (2,355 localidades): más optimista, comparte vecindad con el entrenamiento

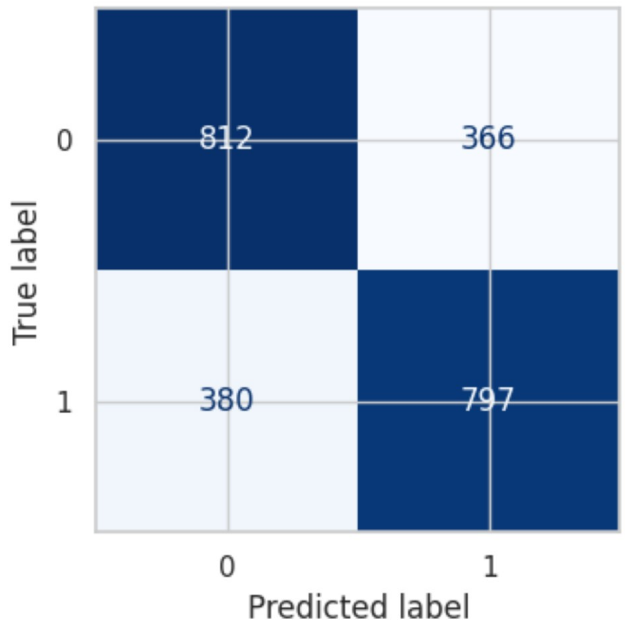
Localidades vecinas se parecen entre sí (autocorrelación espacial). Agrupar por municipio evita que el modelo memorice la vecindad. Se toma **0.73** como referencia para municipios nuevos.

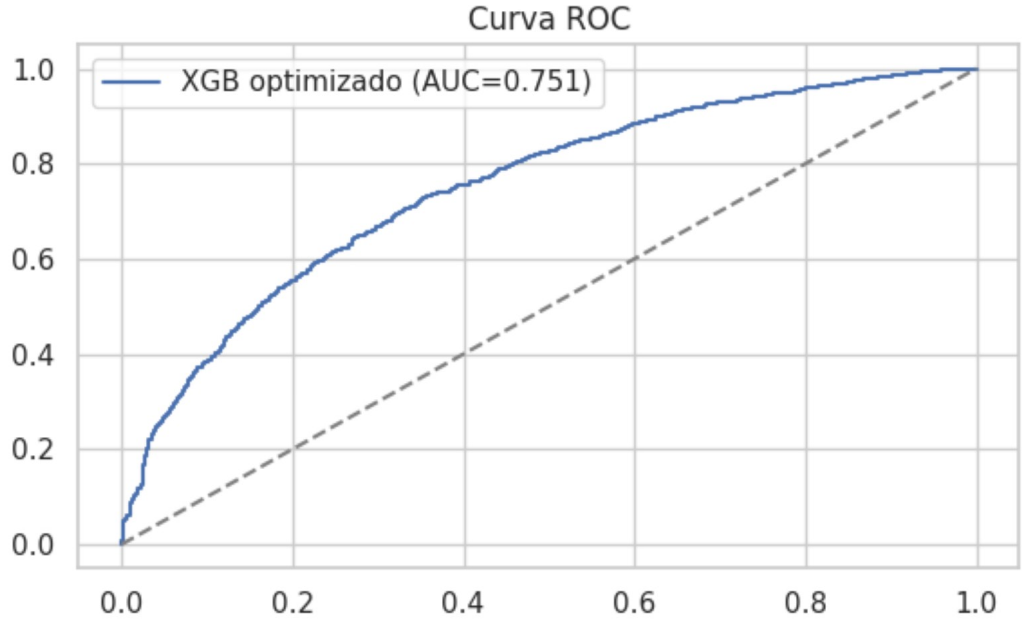
Comparación de modelos

Modelo	AUC CV (por municipio)	AUC test	F1 test
Regresión logística (línea base)	0.659	0.651	0.573
Random Forest	0.714	0.747	0.686
XGBoost base	0.702	0.741	0.677
XGBoost optimizado	0.730	0.751	0.68

Hiperparámetros ganadores: learning_rate 0.05 · max_depth 5 · n_estimators 200 · subsample 0.8.
La familia no lineal aporta +0.10 de AUC sobre la línea base; el ajuste fino, solo +0.01.

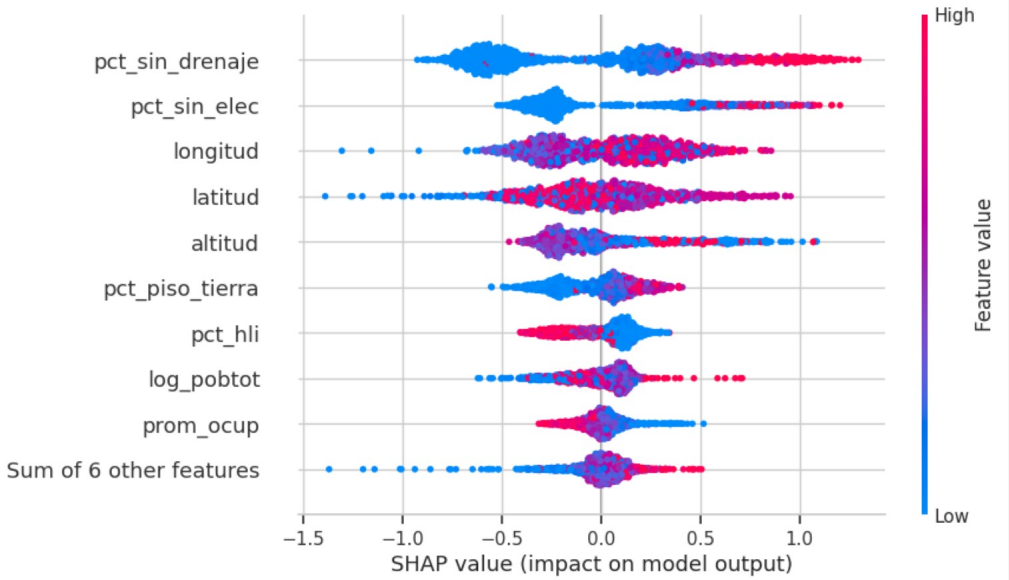
Desempeño del modelo final en el conjunto de prueba





Accuracy 0.68 · precisión y recall entre 0.68 y 0.69 en ambas clases (umbral 0.5). Si un falso negativo cuesta más que una inspección extra, el umbral puede bajarse para ganar sensibilidad.

Qué aprendió el modelo (SHAP)



- **Rezago en servicios:** pct_sin_drenaje y pct_sin_elec lideran; valores altos empujan hacia alta vulnerabilidad.
- **Ubicación:** longitud, latitud y altitud están entre las 5 principales, con efecto regional no monótono.
- **Cautela:** pct_hli y prom_ocup altos empujan hacia menor riesgo. Es un efecto condicional, no causal; validar con el equipo de campo.

Mapa interactivo de riesgo hídrico

Qué muestra

- Probabilidad predicha de alta vulnerabilidad por localidad
- Plotly con estilo carto-positron, sin API key

Al pasar el cursor

- Nombre de la localidad y municipio
- Población, cobertura real de agua y riesgo predicho

Cómo usarlo

- Screening territorial antes de enviar equipos a campo
- Contrastar riesgo predicho contra cobertura real

Muestra las localidades del conjunto de prueba (20%). Un mapa completo de priorización requiere predecir sobre todas las localidades modelables.

Conclusiones y próximos pasos

Resultados

- XGBoost optimizado: AUC 0.73 (por municipio) y 0.75 (test)
- +0.10 de AUC sobre la línea base lineal
- Señal principal: rezago en drenaje y electricidad, y ubicación

Límites

- Excluye 44% de localidades (1 o 2 viviendas, ≈0.9% de la población)
- Objetivo relativo y AUC moderado: priorizar, no diagnosticar
- SHAP describe asociaciones, no causas

Próximos pasos

- Umbrales normativos u objetivo ordinal (menos de 80%, menos de 50%)
- Umbral con mayor sensibilidad
- Variables de vecindad y CONAPO real como validación externa